研究費・公募情報収集システム

PDF自動取得システム 使い方ガイド

指定したWebページから、PDFを自動で集めて整理します

このシステムでできること

1

巡回する

登録したWebページを自動で開きます

2

見つける

ページ内のPDFリンクをすべて探します

3

保存する

サイト別・日付別のフォルダに整理して保存します

例：IPAの試験問題ページから、90件のPDFを約2分で取得できました

処理の流れ

STEP 1
設定を読む
sites.yaml

STEP 2
ページ取得
HTMLを読み込み

STEP 3
リンク抽出
.pdf を検出

STEP 4
重複確認
取得済みは除外

STEP 5
保存・記録
ログも出力

通信エラーは自動で再試行し、失敗した1件があっても、残りの処理は続けます

準備（初回のみ）

① Python 3.12 以上を用意する

お使いのPCに入っているか、コマンドで確認します

```
python --version
```

② 必要なライブラリを入れる

```
pip install -r requirements.txt
```

どちらも最初の1回だけで、次回からは不要です

実行のしかた

```
python src/main.py
```

やりたいこと	コマンド
すべてのサイトを巡回	python src/main.py
特定のサイトだけ実行	--site IPA
設定ファイルを変更	--config 別ファイル.yaml
保存先を変更	--data-dir 保存先

巡回先は、config/sites.example.yaml を sites.yaml にコピーして、name と url を書きます

取得したPDFの保存先

```
data/
├ index.json
├ IPA/
│ └ 2026-10-22/
│ ├ sample.pdf
│ └ sample_1.pdf
└ JST/
logs/2026-10-22.log
```

サイト名 → 取得日の順

フォルダは自動で作られます

同じ名前は連番

sample_1.pdf のように上書きされません

記録は2種類

index.json は取得済みの台帳、logs は実行の履歴です

毎日実行しても、新しいPDFだけ保存

チェック 1

URLで判定

取得済みのURLは、ダウンロードせずに飛ばします

チェック 2

中身で判定

SHA256という識別値が同じなら、別のURLでも保存しません

同じ名前で内容が違うPDFは、別のファイルとして連番で保存します

定期的に自動で動かす

プログラム自体に定期実行の機能はありません。Windowsのタスクスケジューラに登録します

```
schtasks /create /tn "PDF自動取得" /sc daily /st 08:00 /tr "python C:\...\src\main.py"
```

毎朝8時に実行

上のコマンドで登録できます

失敗はすぐ分かる

失敗があると終了コードが 1 になります

使うときの注意点

- 巡回するのは、設定に書いたページ1枚だけです。リンク先のページへはたどりません
- 既定ではrobots.txtを確認し、禁止されたページ・PDFは取得しません。取得するPDFの著作権は、元のサイトにあります
- 相手サーバーに負担をかけないよう、1件ごとに1秒待ちます
- 各サイトの利用規約を必ず確認してからお使いください

今後：PDFの内容をAIで要約・分類する機能を追加できます